Rapport — Prédiction du prix des smartphones

Oct 16, 2026 · Ilian Ikdoumi

Introduction

Quelles caractéristiques techniques font le prix d'un smartphone, et peut-on prédire ce prix à partir d'elles ?

Le projet suit les étapes classiques d'une analyse de données : exploration, nettoyage, analyse graphique, modélisation avec Scikit-learn (régression linéaire puis forêt aléatoire), puis restitution dans un tableau de bord Power BI.

Données et source

Le jeu de données est le « Real-World Smartphone's Dataset » publié sur Kaggle par Abhijit Dahatonde (fichier `smartphones.csv`). Il décrit 980 smartphones de 46 marques vendus sur le marché indien, avec des prix en roupies indiennes (₹).

Chaque téléphone est décrit par 22 colonnes :

Thème	Colonnes
Identification	brand_name, model
Variable à prédire	price (₹)
Avis	avg_rating
Processeur	processor_brand, num_cores, processor_speed (GHz)
Batterie	battery_capacity (mAh), fast_charging_available, fast_charging (W)
Mémoire	ram_capacity (Go), internal_memory (Go), extended_memory_available
Écran	screen_size (pouces), refresh_rate (Hz), resolution_height, resolution_width
Caméras	num_rear_cameras, primary_camera_rear (MP), primary_camera_front (MP)

Thème	Colonnes
Autres	5G_or_not, os

Limite à garder en tête : les données reflètent le marché indien, dominé par des marques chinoises. Les résultats ne se transposent pas tels quels au marché français.

Environnement technique

Le code est écrit en scripts Python numérotés, dans VS Code sur macOS, avec un environnement virtuel propre au projet. Les versions exactes sont figées dans `requirements.txt` pour que le projet soit reproductible.

Outil	Version	Usage
Python	3.12.6	Langage
pandas	3.0.6	Chargement et nettoyage des données
numpy	2.5.4	Calcul numérique
matplotlib	3.11.2	Graphiques
seaborn	0.13.2	Graphiques statistiques
scikit-learn	1.9.1	Modèles de prédiction
Power BI Desktop	—	Tableau de bord (sous Windows, via Parallels Desktop)

Organisation du projet : `data/` (données), `scripts/` (code), `figures/` (graphiques), `dashboard/` (tableau de bord).

Exploration des données

Le jeu de données compte 980 lignes, 22 colonnes et aucun doublon. Il présente des valeurs manquantes dans 8 colonnes, des prix très asymétriques et de nombreuses marques peu représentées.

Valeurs manquantes

Colonne	Manquantes	Remarque
fast_charging	211	143 téléphones sans charge rapide, 68 de puissance inconnue
avg_rating	101	
processor_speed	42	
processor_brand	20	
os	14	
battery_capacity	11	
num_cores	6	
primary_camera_front	5	

Distribution des prix

Indicateur	Prix (₹)
Minimum	3 499
1er décile	8 999
1er quartile	12 999
Médiane	19 994,5
Moyenne	32 520
3e quartile	35 491,5
9e décile	69 999
Maximum	650 000

La moyenne dépasse la médiane de 60 % et l'écart-type (39 532 ₹) dépasse la moyenne : la distribution est fortement asymétrique à droite. La médiane servira donc de prix de référence, et le modèle prédira le logarithme du prix. Le maximum (650 000 ₹) correspond à un téléphone de luxe, très éloigné du reste du marché.

Marques

Les 10 marques les plus présentes (Xiaomi, Samsung, Vivo, Realme, Oppo, Motorola, Apple, OnePlus, Poco, Tecno) regroupent 776 téléphones, soit 79 % du jeu de données. À l'inverse, 25 des 46 marques comptent moins de 5 téléphones, pour 50 téléphones au total (5 %).

Nettoyage

Le jeu de données nettoyé compte 976 téléphones, 22 colonnes et aucune valeur manquante. Il est enregistré dans `data/smartphones_clean.csv`, le fichier brut restant inchangé.

Traitement	Détail	Justification
Puissance de charge rapide	0 W pour les 143 téléphones sans charge rapide ; 33 W (médiane des téléphones avec charge rapide) pour les 68 autres	La valeur 0 est la vraie valeur ; la médiane est calculée sans ces zéros pour ne pas être biaisée
Note moyenne (avg_rating)	Colonne supprimée	101 valeurs manquantes ; un avis client ne s'invente pas et n'existe pas pour un téléphone qui sort
Autres variables numériques	Médiane : 8 cœurs, 2,3 GHz, 5 000 mAh, 16 MP en façade	Moins de 5 % de valeurs manquantes par colonne
Variables textuelles	Modalité la plus fréquente : snapdragon, android	34 valeurs au total
Téléphones de luxe	4 retirés : Vertu Signature Touch, Redmi K20 Pro Signature Edition, Huawei Mate 30 et 50 RS Porsche Design	Prix lié à des matériaux ou à une marque de luxe, pas aux caractéristiques
Petites marques	24 marques de moins de 5 téléphones (49 téléphones) regroupées en « autre »	Trop peu d'exemples pour un apprentissage fiable ; 22 catégories au final
Conversion	Colonne price_eur au taux fixe de 90 ₹ pour 1 €	Taux proche de celui de 2023, année des prix

La suppression des lignes incomplètes a été écartée : elle aurait retiré 211 téléphones (21 %), dont 42 des 46 iPhone. Les valeurs manquantes étaient concentrées sur des téléphones chers, ce qui aurait biaisé l'échantillon vers l'entrée de gamme.

Les téléphones haut de gamme dont le prix s'explique par leur technique sont conservés, comme le Xiaomi Mi Mix Alpha (199 990 ₹), désormais le plus cher, les iPhone 1 To et les Galaxy Z Fold.

Après nettoyage, les prix vont de 39 € à 2 222 €, avec une médiane de 222 € et une moyenne de 345 €.

Analyse graphique

Le stockage est la caractéristique la plus liée au prix (corrélation de 0,70), devant la vitesse du processeur (0,59) et la RAM (0,52). Les six graphiques sont enregistrés dans `figures/`.

Distribution du prix

La distribution du prix est fortement asymétrique : la majorité des téléphones coûte entre 100 et 300 €, avec une longue queue jusqu'à 2 222 €. Son logarithme suit une distribution presque symétrique, centrée autour de 5,4 (soit environ 221 €). Le modèle prédira donc le logarithme du prix.

Marque

Apple a le prix médian le plus élevé (environ 950 €) et Itel le plus bas (environ 65 €). Asus, Sony et Nubia suivent Apple, mais avec moins de 10 téléphones chacune, ce qui rend leur médiane fragile. Samsung, présente sur toute la gamme, a un prix médian d'environ 250 €.

Stockage et RAM

Stockage	Téléphones	Prix médian
64 Go	192	133 €
128 Go	523	244 €
256 Go	156	561 €
512 Go	20	1 117 €
1 To	5	1 922 €

Au-delà de 64 Go, le prix médian double à peu près à chaque doublement du stockage. Le lien avec la RAM est moins net : les iPhone associent 6 Go de RAM à des prix élevés (les 21 téléphones à 6 Go vendus plus de 800 € sont des iPhone), car la RAM n'a pas le même rôle sous iOS et sous Android.

5G

Les 548 téléphones 5G ont un prix médian de 333 €, contre 139 € pour les 428 autres. La 5G signale surtout des téléphones récents et mieux équipés : il s'agit d'une corrélation, dont le modèle permettra d'isoler l'effet propre. Une erreur a été repérée : l'iPhone 15 est indiqué sans 5G.

Corrélations

Corrélations avec le prix : stockage 0,70 ; vitesse du processeur 0,59 ; RAM 0,52 ; 5G 0,45 ; fréquence d'écran 0,37 ; puissance de charge 0,29 ; taille d'écran 0,27 ; caméra principale 0,15 ; batterie -0,14. Le retrait des 4 téléphones de luxe a fait passer la corrélation du stockage de 0,56 à 0,70. Les caractéristiques sont aussi fortement liées entre elles (jusqu'à 0,61 entre RAM et processeur), ce qui compliquera l'interprétation d'une régression linéaire.

Batterie

La corrélation négative de la batterie s'explique par deux effets : les iPhone, chers, ont de petites batteries (médiane de 3 279 mAh contre 5 000 mAh sous Android), et les téléphones Android d'entrée de gamme misent sur de grosses batteries (6 000 à 7 000 mAh). Deux téléphones renforcés dépassent 20 000 mAh (Doogee V Max, Oukitel WP19) ; ces valeurs sont réelles et conservées.

Modélisation

La forêt aléatoire prédit le prix d'un téléphone jamais vu avec une erreur moyenne de 48 € et une erreur médiane de 10,8 %, contre 68 € et 15,1 % pour la régression linéaire.

Méthode

- **Cible** : logarithme du prix en euros, en raison de l'asymétrie de la distribution et du caractère multiplicatif des effets (un doublement du stockage double environ le prix). Les prédictions sont ramenées en euros par l'exponentielle.
- **Variables** : les 19 caractéristiques du jeu nettoyé, hors nom du modèle et prix. La marque, le processeur et l'OS sont encodés en variables indicatrices (one-hot), avec Apple, Bionic et Android comme catégories de référence, soit 51 variables.
- **Validation** : séparation aléatoire en 780 téléphones d'entraînement (80 %) et 196 de test (20 %), graine fixée (random_state = 42).
- **Modèles** : régression linéaire comme référence, puis forêt aléatoire de 300 arbres.
- **Indicateurs** : erreur absolue moyenne (MAE) en euros, R^2 sur le logarithme du prix, erreur relative médiane.

Résultats sur le jeu de test

Modèle	MAE	R^2	Erreur médiane
Régression linéaire	68 €	0,844	15,1 %
Forêt aléatoire	48 €	0,917	10,8 %

La forêt aléatoire réduit l'erreur moyenne d'environ 30 %. Elle capte des interactions que la régression linéaire ne peut pas représenter, comme le rôle différent de la RAM sous iOS et sous Android. Selon la graine aléatoire, sa MAE varie entre 47 et 49 €.

Analyse des erreurs

Les prédictions suivent le prix réel sur toute la gamme, avec une erreur relative assez stable (graphique `figures/07_predit_vs_reel.png`). Le modèle sous-estime les téléphones de plus de 1 000 € : une forêt aléatoire moyenne des exemples vus et ne peut pas dépasser les extrêmes de l'entraînement, où les téléphones très chers sont rares.

Importance des variables

Variable	Importance
Vitesse du processeur	0,49
RAM	0,08
Résolution (largeur)	0,06
Stockage	0,06
Résolution (hauteur)	0,06
Puissance de charge	0,05
Caméra avant	0,04
iOS	0,03

La vitesse du processeur concentre près de la moitié de l'importance, alors que le stockage était la variable la plus corrélée au prix. Les caractéristiques étant fortement liées entre elles, la forêt retient celle qui sépare le mieux les gammes, et l'importance se répartit entre variables proches. Ces valeurs indiquent donc surtout que le niveau matériel global détermine le prix, plutôt qu'un classement exact des caractéristiques. L'effet de la marque apparaît faible car l'encodage la répartit sur 21 variables.

Tableau de bord Power BI

Un tableau de bord d'une page (`dashboard/smartphones.pbix`) permet d'explorer le marché sans code, à partir du fichier `data/smartphones_powerbi.csv` produit par le script `05_export_powerbi.py` .

Préparation des données

Le script ajoute une gamme de prix et des libellés lisibles, et ne conserve que 13 colonnes.

Gamme	Seuil	Téléphones	Part
Entrée de gamme	< 200 €	415	42,5 %
Milieu de gamme	200 à 500 €	380	38,9 %
Haut de gamme	> 500 €	181	18,5 %

Power BI en français interprétant le point décimal comme du texte, les prix sont exportés en entiers et les autres colonnes décimales sont converties dans Power Query avec les paramètres régionaux anglais.

Contenu

- Deux indicateurs : 976 téléphones et un prix médian de 222 €.
- Le prix médian par marque, trié de la plus chère (Apple, environ 945 €) à la moins chère (Itel, environ 65 €).
- La répartition des téléphones par gamme de prix.
- Le prix selon le stockage, un point par téléphone, coloré par système d'exploitation, en échelles logarithmiques.
- Trois filtres (marque, système, 5G) qui s'appliquent à tous les visuels.

Plus de quatre téléphones sur cinq coûtent moins de 500 € : le marché étudié est dominé par l'entrée et le milieu de gamme.

Conclusion

Les caractéristiques techniques suffisent à prédire l'essentiel du prix d'un smartphone : la forêt aléatoire estime le prix d'un téléphone jamais vu à 48 € près en moyenne, avec une erreur médiane de 10,8 %.

Le prix est porté par le niveau matériel global : stockage, vitesse du processeur et RAM, fortement liés entre eux. La 5G marque surtout des téléphones récents, et la batterie est légèrement associée à des prix plus bas.

Limites

- Les données concernent le marché indien vers 2023 et ne se transposent pas telles quelles au marché français.
- Le fichier ne contient ni date de sortie, ni matériaux, ni image de marque : ces facteurs expliquent une partie des erreurs restantes, notamment la sous-estimation des téléphones de plus de 1 000 €.
- Le taux de change est fixé à 90 ₹ pour 1 €.

Pistes d'amélioration

- Ajouter la date de sortie et le prix de lancement pour tenir compte de l'âge du téléphone.
- Évaluer les modèles par validation croisée plutôt que sur une seule séparation entraînement / test.
- Tester d'autres modèles, comme le gradient boosting.